

Analyse des biais et de l'équité

Survie globale dans la leucémie aiguë myéloïde

3 août 2026

Résumé

Un C-index global de 0,752 décrit le comportement *moyen* d'un modèle, mais ne dit rien sur *qui* il sert bien. Ce rapport audite un Random Survival Forest entraîné sur 3 323 patients atteints de LAM (Leucémie Aiguë Myéloïde) en examinant si la qualité prédictive est répartie équitablement entre les sous-groupes de patients. Deux méthodes indépendantes établissent que le modèle ne s'appuie pas sur l'hôpital de prise en charge. En revanche, l'analyse de calibration révèle un biais d'optimisme systématique et reproductible pour les groupes cytogénétiques défavorables, invisible aux métriques de discrimination.

Table des matières

1	Introduction	3
2	Une taxonomie des biais	3
2.1	Biais au niveau des données	3
2.2	Biais au niveau du modèle	3
2.3	Fuite d'information et confusion	4
2.4	Biais de déploiement	4
3	Pourquoi les modèles de survie exigent un cadre d'équité spécifique	4
4	Application à notre étude	5
4.1	Axes disponibles	5
4.2	Facteurs de confusion identifiés avant l'analyse	5
5	Méthodologie	6
5.1	Discrimination par sous-groupe	6
5.2	Calibration par sous-groupe	6
5.3	Dépendance aux variables institutionnelles	6
5.4	Contrôle du surapprentissage	6
6	Résultats	6
6.1	Discrimination : aucun biais détectable	6
6.2	Dépendance institutionnelle	7
6.3	Calibration : biais systématique sur les groupes défavorables	7
7	Inventaire des biais	8
7.1	Confirmés	8
7.2	Recherchés et écartés	8
7.3	Non évaluables	9
8	Discussion	9
9	Limites	9

1 Introduction

Un indicateur de performance global décrit le comportement *moyen* d'un modèle. Il ne dit rien sur **qui** le modèle sert bien et qui il sert mal. Un modèle atteignant un C-index de 0,752 peut être excellent pour la majorité des patients et peu fiable pour un sous-groupe spécifique et potentiellement vulnérable.

L'analyse des biais répond à une question que les métriques agrégées ne peuvent pas traiter : **la qualité prédictive est-elle répartie équitablement entre les sous-groupes de patients, ou le modèle désavantage-t-il systématiquement une population identifiable ?**

En contexte clinique, cette question n'est pas seulement statistique. Un outil pronostique qui surestime la survie des patients à haut risque pourrait contribuer à un sous-traitement, à un retard d'orientation vers des filières de soins intensifs, ou à une réassurance inappropriée. *La direction d'une erreur importe autant que son amplitude.*

2 Une taxonomie des biais

Les biais d'une chaîne d'apprentissage automatique peuvent naître à quatre stades distincts. Les différencier importe, car chacun appelle un remède différent.

2.1 Biais au niveau des données

Introduits avant tout entraînement de modèle.

Type	Définition	Conséquence typique
Échantillonnage / représentation	Certains sous-groupes sont sous-représentés par rapport à la population cible	Le modèle apprend mal ces groupes
Sélection	Les critères d'inclusion excluent systématiquement une catégorie de patients	Les prédictions ne se généralisent pas au-delà de la population recrutée
Survie (<i>survivorship</i>)	Les individus ayant connu l'événement précocement sont absents par construction	La survie est structurellement surestimée
Mesure	Une variable est enregistrée différemment selon les sources ou les périodes	Le modèle apprend des artefacts de mesure plutôt que la biologie
Annotation / documentation	Les données manquantes sont concentrées sur certains groupes plutôt qu'aléatoires	L'absence de donnée devient elle-même un signal et une inéquité

2.2 Biais au niveau du modèle

Issus de l'algorithme d'apprentissage lui-même, même sur des données équilibrées.

Type	Définition	Conséquence typique
Calibration	Les probabilités prédites s'écartent systématiquement des fréquences observées	Classement correct, mais risque absolu erroné

Type	Définition	Conséquence typique
Régression vers la moyenne	Le moyennage d'ensemble ramène les prédictions extrêmes vers le centre de la distribution	Cas sévères et bénins sont tous deux insuffisamment différenciés
Discrimination	La qualité de classement diffère selon les sous-groupes	Le modèle est moins utile pour certains patients
Agrégation	Un modèle unique est ajusté là où les sous-groupes suivent des relations sous-jacentes différentes	Aucun sous-groupe n'est servi de façon optimale

2.3 Fuite d'information et confusion

Type	Définition	Conséquence typique
Fuite contextuelle	Une variable technique ou administrative porte du signal pronostique	La performance ne se transfère pas à un nouveau contexte
Institutionnel	Le modèle s'appuie sur le centre traitant plutôt que sur les caractéristiques du patient	Le pronostic dépend du lieu de soins, non de la biologie
Proxy	Une variable neutre encode un attribut protégé ou structurel	Discrimination indirecte

2.4 Biais de déploiement

Type	Définition	Conséquence typique
Dérive de distribution	La population de déploiement diffère de la population d'entraînement	Dégradation silencieuse de la performance
Entrée hors distribution	L'interface autorise des saisies jamais observées à l'entraînement	Prédictions produites sans fondement empirique
Automatisation	Les utilisateurs surestiment la fiabilité des sorties	Amplification de tout biais résiduel

3 Pourquoi les modèles de survie exigent un cadre d'équité spécifique

Les métriques d'équité usuelles : parité démographique, égalité des chances, égalité des opportunités, supposent un cadre de **classification** avec des issues binaires pleinement observées. Aucune de ces hypothèses ne tient ici.

L'issue est une durée, non une étiquette. Il n'existe pas de matrice de confusion, donc aucun taux de faux positifs ou de faux négatifs à égaliser entre groupes.

L'issue est censurée à droite pour environ 48 % des patients. Pour près de la moitié de la cohorte, nous savons seulement que le patient était vivant aux dernières nouvelles. Deux conséquences méthodologiques en découlent :

- **Le C-index dépend de la distribution de la censure.** Un sous-groupe au suivi court produit moins de paires comparables, donc une estimation instable. Les écarts bruts entre groupes ne peuvent être interprétés comme un biais sans contrôler ce facteur.
- **Kaplan–Meier est la seule référence non biaisée** pour la survie observée, et sa fiabilité se dégrade à mesure que la censure augmente.

Discrimination et calibration sont deux défaillances indépendantes. Un modèle peut classer correctement les patients d'un sous-groupe tout en se trompant systématiquement sur leur survie absolue. Cliniquement, la seconde erreur est la plus dangereuse, et elle est totalement invisible au C-index. Tout audit d'équité crédible d'un modèle de survie doit donc évaluer **les deux**.

4 Application à notre étude

4.1 Axes disponibles

Le jeu de données contient : ID, CENTER, BM_BLAST, WBC, ANC, MONOCYTES, HB, PLT, CYTOGENETICS, CYTO_CLASS, OS_YEARS, OS_STATUS, ainsi que les agrégats moléculaires au niveau patient.

Aucune variable d'âge ni de sexe n'est disponible. L'équité démographique ne peut donc **pas être évaluée**. Cette limite est énoncée explicitement plutôt que contournée. Il s'agit également d'une faiblesse de modélisation en soi : l'âge est le deuxième facteur pronostique de la LAM après la cytogénétique.

Trois axes restent analysables :

Axe	Modalités	Question d'équité
CENTER	23 centres hospitaliers	Le pronostic dépend-il du lieu de prise en charge ?
CYTO_CLASS	8 groupes de risque ELN 2022	Le modèle est-il aussi fiable pour les patients à risque défavorable que favorable ?
HAS_MOL_DATA	testé / non testé	Le modèle dessert-il les patients sans profilage moléculaire ?

CENTER est l'axe le plus sensible, car il s'agit d'une **variable du modèle lui-même**. Le RSF a pu apprendre des différences institutionnelles de prise en charge, de recrutement ou de documentation plutôt que la biologie du patient, un cas d'école de biais institutionnel.

4.2 Facteurs de confusion identifiés avant l'analyse

La censure est très hétérogène entre centres , de 8,4 % à 90,2 %, et corrèle avec la survie apparente :

Les centres au suivi court paraissent obtenir de meilleurs résultats simplement parce que moins de décès y ont été observés. Il s'agit d'un artefact de censure, non d'une différence clinique.

Les effectifs sont fortement déséquilibrés , de 786 patients (KI) à 6 (REL), et de 1 780 (Normal) à 79 (Complex). Les estimations en dessous d'environ 50 patients sont statistiquement ininterprétables.

Centre	n	Censure	KM $S(2\text{ans})$	Suivi max.
MUV	83	8,4 %	0,446	12,79 ans
UOB	86	18,6 %	0,581	14,70 ans
CCH	140	76,4 %	0,834	9,32 ans
ROM	102	90,2 %	0,809	2,84 ans

5 Méthodologie

5.1 Discrimination par sous-groupe

C-index calculé **au sein** de chaque sous-groupe, avec **intervalles de confiance bootstrap à 95 %** (200 rééchantillonnages). Les sous-groupes comptant moins de 50 patients ou 15 événements sont rapportés mais non interprétés.

Règle de décision : un biais n'est conclu que lorsque les intervalles de confiance sont **disjoints**. Avec des effectifs s'étendant sur deux ordres de grandeur, le chevauchement des intervalles est le résultat attendu même sous équité parfaite.

5.2 Calibration par sous-groupe

Survie moyenne prédite à 2 ans comparée à l'estimation **Kaplan–Meier** observée dans le même sous-groupe :

$$\text{écart} = \overline{\hat{S}(2\text{ans})} - S_{\text{KM}}(2\text{ans}) \quad (1)$$

Un **écart positif signifie que le modèle est trop optimiste** pour ce groupe. Le taux de censure est reporté en regard de chaque écart, un sous-groupe fortement censuré fournissant une référence KM peu fiable.

5.3 Dépendance aux variables institutionnelles

Test de permutation : la colonne **CENTER** est mélangée aléatoirement et la perte de C-index mesurée (5 répétitions). Si le modèle s'appuie réellement sur l'hôpital de prise en charge, détruire cette information devrait dégrader la performance. Une chute inférieure à $\sim 0,005$ indique une dépendance négligeable. Ce résultat est recoupé avec l'analyse SHAP menée indépendamment au niveau du patient individuel.

5.4 Contrôle du surapprentissage

Les métriques par sous-groupe étant calculées sur les données d'entraînement, l'analyse de calibration est répétée sur un échantillon retenu (25 %, stratifié sur le statut d'événement) afin de vérifier que toute mauvaise calibration observée n'est pas un artefact de mémorisation.

6 Résultats

6.1 Discrimination : aucun biais détectable

Résultats par centre (sélection) :

Même les extrêmes (CGM à 0,896, RMCN à 0,752) ne sont pas nettement séparés une fois l'incertitude prise en compte. **Le modèle classe les patients avec une efficacité comparable dans tous les sous-groupes évaluable.**

Axe	Intervalle observé	Évaluables	Conclusion
CENTER	0,752 – 0,896	11 / 23	IC tous chevauchants → pas de biais
CYTO_CLASS	0,743 – 0,817	7 / 8	tendance faible, non significative
HAS_MOL_DATA	0,798 vs 0,810	2 / 2	pas d'inéquité d'accès

Centre	n	événements	C-index	IC 95 %
CGM	107	37	0,896	[0,848 – 0,932]
PV	316	81	0,861	[0,828 – 0,898]
DUS	445	288	0,807	[0,784 – 0,832]
KI	786	483	0,800	[0,781 – 0,820]
RMCN	182	105	0,752	[0,707 – 0,802]

Par classe cytogénétique, un léger gradient apparaît : **Normal / 5q deletion** autour de 0,80–0,82 contre **Monosomy 7** (0,743) et **Complex** (0,747) mais les intervalles se chevauchent. L'interprétation la plus plausible est structurelle plutôt qu'un défaut du modèle : dans les groupes de très mauvais pronostic, la plupart des patients décèdent rapidement, laissant moins à discriminer.

6.2 Dépendance institutionnelle

Test	Résultat
C-index (référence)	0,8105
Chute lors de la permutation de CENTER	0,0051 ± 0,0002
Impact relatif	0,6 % de la performance

Détruire toute information sur l'hôpital de prise en charge coûte au modèle 0,5 % de point de C-index. Ce résultat est corroboré indépendamment par l'analyse SHAP, où *Centre de traitement* contribue ≈ 0 aux prédictions individuelles.

Le pronostic ne dépend pas du lieu de prise en charge. Il s'agit d'un résultat négatif, et solide : la variable est présente dans le modèle mais reste effectivement inerte.

6.3 Calibration : biais systématique sur les groupes défavorables

Il s'agit du résultat principal.

Le modèle est systématiquement trop optimiste pour les patients à cytogénétique défavorable. Pour les caryotypes complexes, il prédit 42,5 % de survie à deux ans là où 26,9 % sont observés, soit une surestimation de 15,6 points.

Trois éléments établissent qu'il s'agit d'un véritable biais du modèle et non de bruit :

1. **Le gradient est monotone.** Plus le pronostic est sombre, plus la surestimation est forte. Les groupes favorables et majoritaires sont bien calibrés ($|\text{écart}| < 0,02$).
2. **Il se reproduit hors échantillon.** Les écarts hold-out (+0,148, +0,102) correspondent presque exactement aux écarts d'entraînement (+0,156, +0,099), ce qui exclut le surapprentissage.
3. **Ce n'est pas un artefact de censure.** **Monosomy 7** ne présente que 14,7 % de censure dans l'échantillon retenu, sa référence Kaplan–Meier est donc fiable.

Groupe	n	Prédit	Observé	Écart	Hold-out	Censure
Complex	79	0,425	0,269	+0,156	+0,148	27,8 %
Monosomy 7	164	0,345	0,246	+0,099	+0,102	25,0 %
Trisomy 8	181	0,479	0,428	+0,052	+0,021	35,9 %
Missing	285	0,600	0,591	+0,009	+0,004	40,4 %
5q deletion	296	0,567	0,560	+0,007	−0,051	41,2 %
Other	304	0,599	0,608	−0,010	+0,016	48,7 %
Normal	1780	0,679	0,699	−0,020	−0,024	57,2 %

Mécanisme. Il s'agit d'une **régression vers la moyenne**, propriété attendue des forêts aléatoires : chaque prédiction agrège des moyennes de feuilles, ce qui ramène les cas extrêmes vers le centre de la distribution des issues. Les groupes concernés sont simultanément les plus sévères et les moins représentés (79 et 164 patients), ce qui amplifie l'effet. Le biais *naît donc dans les données* (sous-représentation des cas sévères) et *se manifeste dans le modèle* (contraction de leur risque prédit).

Portée clinique. L'erreur va dans la direction la plus préjudiciable : annoncer un pronostic plus favorable que la réalité aux patients les plus à risque. Elle est totalement invisible au C-index. **Complex** conserve une discrimination honorable de 0,747 et n'apparaît que par l'analyse de calibration. Cela valide la méthodologie en deux volets.

7 Inventaire des biais

7.1 Confirmés

Biais	Preuve	Origine
Calibration / régression vers la moyenne	+0,156 (Complex), +0,099 (Monosomy 7), reproduit hors échantillon	Modèle, induit par le déséquilibre des données
Représentation	786 → 6 patients par centre ; 1 780 → 79 par classe cytogénétique	Données
Censure	8,4 % → 90,2 % selon les centres, corrélée à la survie apparente	Données / protocole d'étude
Documentation	285 patients avec CYTO_CLASS = Missing, 256 sans test moléculaire	Recueil des données
Fuite contextuelle (suspectée)	DEPTH_MEAN / DEPTH_MAX portent du signal pronostique bien que purement techniques	Ingénierie des variables

7.2 Recherchés et écartés

Biais	Preuve
Institutionnel	La permutation de CENTER coûte 0,0051 de C-index ; contribution SHAP ≈ 0
Discrimination	Tous les intervalles de confiance par sous-groupe se chevauchent
Inéquité d'accès aux soins	HAS_MOL_DATA : 0,798 vs 0,810, intervalles chevauchants

7.3 Non évaluables

Biais	Raison
Démographique	Ni l'âge ni le sexe ne figurent dans le jeu de données
Sélection	Aucune information sur les patients exclus ni sur les filières d'adressage
Survie (<i>survivorship</i>)	Les patients décédés avant caryotype sont absents par construction

8 Discussion

L'analyse produit un résultat négatif solide et un résultat positif solide, et le contraste entre les deux est instructif.

Le résultat négatif est rassurant. Bien que CENTER soit une variable explicite du modèle (configuration qui susciterait normalement l'inquiétude) le modèle ne l'exploite pas. Deux méthodes indépendantes (test de permutation au niveau populationnel, SHAP au niveau individuel) convergent vers la même conclusion. Le modèle fonde son pronostic sur la biologie, non sur le contexte institutionnel.

Le résultat positif est actionnable. Le biais de calibration est systématique, reproductible, et va dans la direction cliniquement préjudiciable. Point crucial : il serait passé totalement inaperçu si l'audit s'était limité aux métriques de discrimination. **Complex** affiche en effet un C-index de 0,747, que toute évaluation standard jugerait acceptable.

Cela illustre le point méthodologique central du rapport : **pour les modèles de survie, la qualité de classement et l'exactitude du risque absolu sont deux propriétés distinctes, et l'équité doit être évaluée sur les deux.** Un modèle peut classer parfaitement un sous-groupe tout en se trompant systématiquement sur la durée de vie réelle de ses patients.

Le mécanisme éclaire également le lieu où doit intervenir la correction. Le biais découlant de la sous-représentation des cas sévères combinée au moyennage d'ensemble, un changement d'algorithme a peu de chances de le résoudre. Le recalibrage post-hoc ou la repondération des cas sévères constituent les directions appropriées.

9 Limites

- **Les métriques sont calculées sur les données d'entraînement.** Les C-index par sous-groupe autour de 0,80 correspondent au C-index d'entraînement (0,8105), non au score de la plateforme de test (0,752). Les valeurs absolues sont optimistes ; seules les *comparaisons relatives entre sous-groupes* sont interprétables.
- **L'échantillon retenu est imparfait.** Il est tiré de patients que le modèle a vus durant l'entraînement. Une calibration validée croisée, mesurée sur chaque fold de validation, serait nécessaire pour une preuve de niveau publication.
- **Petits sous-groupes.** 12 centres sur 23 sont en dessous du seuil d'interprétabilité. **Complex** et **Monosomy 7** en hold-out reposent respectivement sur 22 et 34 patients (résultats indicatifs, à confirmer sur une cohorte externe).
- **Aucune variable démographique,** l'axe d'équité le plus couramment examiné est donc inaccessible.

- **Un horizon unique** (2 ans) a été utilisé pour la calibration. Le biais pourrait se comporter différemment à 1 ou 5 ans.
- **Entrées hors distribution dans l'application.** L'interface Streamlit propose des classes cytogénétiques absentes de l'entraînement (`inv(16)`, `t(8;21)`) ou représentées par un seul patient (`APL t(15;17)`), ce qui produirait des prédictions sans fondement empirique. Il s'agit d'un biais de déploiement identifié durant l'audit et nécessitant correction avant toute utilisation.